基于大语言模型的非功能需求生成方法小规模复现实验报告

张瑞淇
大数据与软件学院

2026 年 10 月 27 日

摘要

本文对《基于大语言模型的非功能需求生成方法》进行小规模复现。利用 37 条功能需求—非功能需求（FR-NFR）对，按 8:2 划分为 30 条案例库与 7 条测试集，构建基于 bge-small-zh-v1.5 嵌入、MMR 检索、五段式提示工程与 DeepSeek 生成的非功能需求自动生成流程。实验设置三种条件：A（无检索）、B（top1 检索）、C（MMR top5 检索），并从检索质量、自动指标和双人盲评三个维度评估。结果表明：检索结果中高 + 中相关案例占比 57.1%，整体可用；C 条件在可量化比例（0.8784）、BLEU（0.0393）与 ROUGE-L（0.1140）上均为最优；人工盲评中 C 条件三项均为 4.33 分，总平均 4.33 为三者最高且最均衡。受限于 30 条案例库规模与部分领域案例缺失，C 条件未在单项上形成压倒性优势，但在均衡性与可测试性上复现了原论文的核心趋势。

关键词：软件需求工程；非功能需求；大语言模型；检索增强生成；提示工程

1 引言

非功能需求（Non-Functional Requirement, NFR）描述系统在性能、安全、可靠性、可用性等方面的质量约束，对软件系统成败具有关键影响。传统 NFR 获取依赖需求工程师人工分析，效率低且易遗漏；基于文档的自动提取方法只能识别显式表达的 NFR；直接使用大语言模型（LLM）生成 NFR 则面临知识幻觉与领域专业性不足的问题。

原论文提出融合检索增强生成（RAG）与提示工程的 NFR 自动生成方法，在 3000 条案例库上取得显著效果。本文在 37 条小规模数据上复现其核心流程，重点验证以下问题：

1. 在小规模案例库下，MMR 检索能否召回与输入 FR 相关的历史案例？
2. RAG+ 提示工程能否提升生成 NFR 的可量化比例与可测试性？

3. 小规模数据下，C 条件相对 A/B 条件的优势是否仍然存在?

2 方法

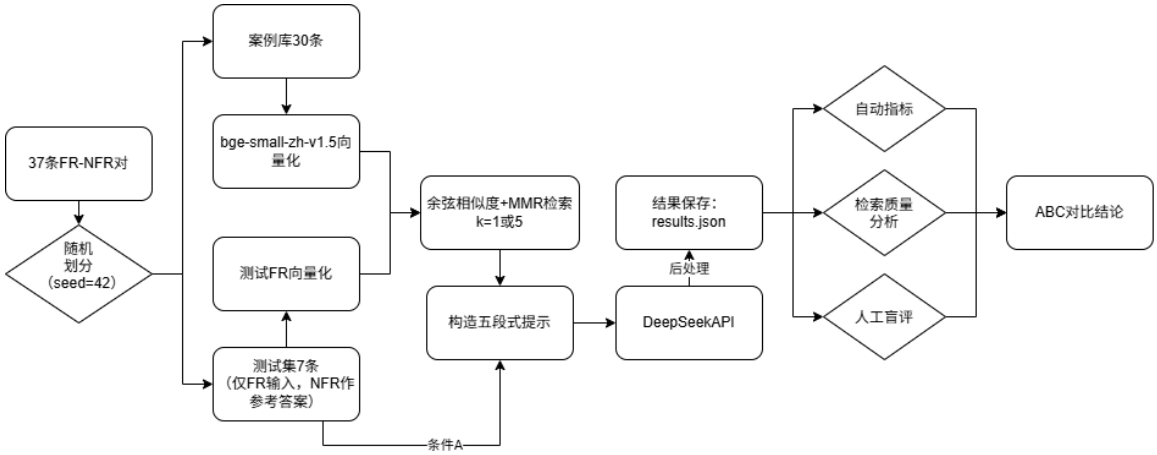


图 1: 小规模复现实验流程图

2.1 数据集与划分

实验数据共 37 条 FR-NFR 对，覆盖图书馆借阅、电商订单、留言评论、聊天、多语言、库存、报表、权限等多个领域。每条记录包含功能需求文本与若干条关联非功能需求。按随机种子 42 将数据划分为 30 条案例库与 7 条测试集，测试集仅输入 FR，其 NFR 作为参考答案。

2.2 检索模块

采用 `BAAI/bge-small-zh-v1.5` 将功能需求编码为归一化向量，存入向量库。输入测试 FR 后，计算其与案例库 FR 的余弦相似度，并采用最大边际相关性（MMR）算法选取 top-k 案例：

$$\mathrm{MMR}(i) = \lambda \cdot \mathrm{sim}(q, d_i) - (1-\lambda) \cdot \max_{j \in S} \mathrm{sim}(d_i, d_j), \tag{1}$$

其中 q 为查询，S 为已选案例集，$\lambda = 0.7$。实验设置 $k = 1$（条件 B）与 $k = 5$（条件 C）。

2.3 提示工程

提示模板由五部分构成：角色定位（资深需求分析师，精通 ISO/IEC 25010）、任务背景（新 FR 与历史案例）、分析步骤（功能场景分析 → 质量属性分析 → 经验参考与创新 → 需求生成）、输出格式（列表形式、具体可度量）、情感激励（强调任务重要性）。条件 A 不注入历史案例，条件 B 与 C 分别注入 top1 与 top5 案例。

2.4 生成与后处理

调用 DeepSeek API（`deepseek-chat`），温度 0.9、top_p 0.9、frequency_penalty 0.5，每条 FR 每个条件生成一次。后处理阶段仅保留“需求生成”之后的 NFR 列表项，去除分析段、引导语、Markdown 标记与重复句。

2.5 评估方法

自动指标：NFR 条数、可量化比例（含数字 + 单位的条目占比）、类别覆盖率（性能/安全/可靠/可维护/易用/兼容六类）、BLEU、ROUGE-1、ROUGE-L（中文按字切分）。

人工盲评：从 7 条测试 FR 中选取 3 条（借阅列表、留言板评论、多语言切换），将 A/B/C 三种结果随机编号为 S01–S09，邀请 2 名软件工程背景评分者按完整性、准确性、可测试性 1–5 分盲评。评分标准采用原论文表 2 精简版：完整性看质量属性覆盖与约束具体性；准确性看术语规范与专业程度；可测试性看量化指标与验证方法。

3 实验设置

表 1: 三种实验条件

条件	检索	提示
A 无检索	无	角色 + 任务 + 步骤 + 格式 + 情感
B top1	MMR $k = 1$	五段式 +1 条历史案例
C MMR top5	MMR $k = 5$	五段式 +5 条历史案例

实验环境：Python 3.12，sentence-transformers，openai SDK，DeepSeek API。全部代码与数据见项目目录。

4 实验结果

4.1 检索质量分析

对 7 条测试 FR 的 MMR top5 检索结果，按“业务场景—操作类型—NFR 类型”三维标准逐条标注高/中/弱/无关，结果如表 2 所示。

表 2: 检索结果相关性分析

#	测试 FR	高	中	弱	无关	结论
1	借阅者查看借阅列表	1	3	1	0	合格
2	编辑网页预览内容	0	3	2	0	合格
3	管理员查看销售报表	0	1	2	2	勉强合格
4	访客浏览留言板评论	2	2	0	1	合格
5	按 SKU 查询库存	0	4	0	1	合格
6	查看历史聊天记录	1	0	2	2	勉强合格
7	多语言界面切换	0	3	1	1	合格
	合计	4	16	8	7	合格 6/勉强 1/不合格 0

7 条测试 FR 全部至少有 1 条中相关以上案例，无完全跑偏；高 + 中相关案例占比 57.1%。强相关偏少主要因为 37 条数据跨领域混合，部分功能（如多语言切换、销售报表）在案例库中缺乏同领域相似案例。

4.2 自动指标

表 3: 自动指标对比（修复后处理）

指标	A 无检索	B top1	C MMR top5
NFR 条数	**20.29**	13.43	13.86
可量化比例	0.7716	0.8218	**0.8784**
类别覆盖率	**1.0000**	0.8571	0.9286
BLEU	0.0274	0.0337	**0.0393**
ROUGE-1	0.1251	**0.1611**	0.1610
ROUGE-L	0.0828	0.1069	**0.1140**

C 条件在可量化比例、BLEU、ROUGE-L 三项上最优，ROUGE-1 与 B 基本持平；A 条件 NFR 条数最多但可量化比例最低，说明其“多”主要来自泛泛表述；C 条件条数较少但可量化比例最高，条目更精炼、更可测试。

4.3 人工盲评

两位评分者对 9 份匿名方案打分，S06 经复核后将可测试性统一调整为 3 分。按条件合并平均如表 4 所示。

表 4: 双人盲评平均分（合并）

条件	完整性	准确性	可测试性	总平均
A 无检索	**4.67**	3.50	**4.50**	4.22
B top1	3.67	**4.83**	4.33	4.28
C MMR top5	4.33	4.33	4.33	**4.33**

C 条件三项均为 4.33，总平均 4.33 为三者最高且最均衡：相比 A，准确性提升 0.83；相比 B，完整性提升 0.66。A 完整性最高但准确性最低，B 准确性最高但完整性最低。准确性维度两位评分者存在标准差异，评分者 1 更严格。

4.4 案例分析

以测试 FR“借阅者应能查看自己当前借阅的图书列表” 为例，C 条件生成的部分 NFR 如下：

- 借阅列表查询接口在正常负载下 P95 响应时间不超过 2 秒，P99 不超过 4 秒（返回单页不超过 20 条记录）。
- 在 300 并发借阅者同时查询各自借阅列表的场景下，接口错误率低于 0.1%，平均响应时间不超过 3 秒。
- 借阅者完成借书或还书操作后，其本人借阅列表的查询结果在 1 秒内反映最新状态（读己之写一致性延迟 ≤1 秒）。
- 跨用户访问请求须在服务端被拒绝并返回 403，越权尝试须记录审计日志，日志写入成功率 100%。
- 当缓存服务不可用时，须自动降级为直接查询主数据库，降级切换时间不超过 10 秒，降级期间 P95 响应时间不超过 5 秒。
- 借阅列表接口在弱网（往返时延 200ms、丢包率 1%）条件下，首屏数据加载成功率不低于 99%。
- 单借阅者每秒查询不超过 5 次，超限请求返回 429，限流误判率低于 0.1%。

上述条目均含明确场景、指标或验证方法，可直接转化为测试用例。相比之下，A 条件生成内容虽条数更多，但包含较多 “系统应保证高可用性”“应提供良好体验” 类泛泛表述。

5 讨论

5.1 与原论文对比

原论文在 3000 条案例库、10 位专家评分下，C 条件在完整性（4.71）、准确性（4.75）、可测试性（4.63）上均最高。本文 C 条件总平均最高（4.33）且最均衡，但完整性与准

确性未形成单项碾压，主要差异原因：

1. 案例库规模：30 条 vs 3000 条，检索噪声更大；
2. 评分者数量：2 人 vs 10 人，准确性维度标准差异明显；
3. 自动指标局限：BLEU/ROUGE 对长度差异敏感，对“条数多但泛泛”的 A 条件存在宽容。

5.2 局限性

- 数据规模小、领域混合，部分测试 FR 缺乏同领域相似案例（如多语言切换、销售报表）；
- 单次生成、未取多次平均，LLM 随机性可能影响结果；
- 人工评分样本仅 3 条 FR、2 位评分者，结论为方向性；
- 未验证 NFR 层次性与系统级协同生成。

6 结论

本文在 37 条 FR-NFR 对上复现了基于 RAG 与提示工程的 NFR 生成方法。检索结果整体可用（高 + 中占比 57.1%）；自动指标显示 C 条件在可量化比例、BLEU、ROUGE-L 上最优；人工盲评显示 C 条件总平均 4.33 最高且三项最均衡。结果表明，在小规模案例库下仍能复现“检索增强 + 结构化提示提升 NFR 可测试性与均衡性”的核心趋势，但检索质量依赖案例库领域覆盖度，自动指标不足以单独评价 NFR 质量，需结合人工评分与案例分析。

参考文献

[1] 欧阳柳波, 叶巧莹, 孟心如, 杜漫茹. 基于大语言模型的非功能需求生成方法. 软件学报. http://www.jos.org.cn/1000-9825/7557.htm

[2] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS, 2020.

[3] ISO/IEC 25010:2011. Systems and software engineering—Systems and software quality requirements and evaluation (SQuaRE)—System and software quality models. 2011.

[4] Carbonell J, Goldstein J. The use of MMR, diversity-based reranking for reordering documents and producing summaries. SIGIR, 1998.

[5] Papineni K, Roukos S, Ward T, Zhu WJ. BLEU: a method for automatic evaluation of machine translation. ACL, 2002.

[6] Lin CY. ROUGE: A package for automatic evaluation of summaries. ACL Workshop, 2004.

A 核心代码清单

A.1 MMR 检索

```python
def retrieve_mmr(query, k=5, lam=0.7):
    q_emb = model.encode([query], normalize_embeddings=True)[0]
    sims = lib_emb @ q_emb
    selected, candidates = [], list(range(len(lib_fr)))
    while len(selected) < k and candidates:
        if not selected:
            best = max(candidates, key=lambda i: sims[i])
        else:
            def mmr(i):
                max_sim = max(float(lib_emb[i] @ lib_emb[j]) for j in
                    selected)
                return lam * float(sims[i]) - (1-lam) * max_sim
            best = max(candidates, key=mmr)
        selected.append(best)
        candidates.remove(best)
    return selected
```

A.2 后处理

```python
def postprocess(text):
    lines, start_idx = text.splitlines(), 0
    for i, line in enumerate(lines):
        if re.search(r"(需求生成|非功能需求如下|NFR列表)", line):
            start_idx = i + 1
            break
    out, seen = [], set()
```

```
    for raw in lines[start_idx:]:
        line = re.sub(r"^[\*\-\d\.\)、\s]+", "", raw.strip())
        if len(line) < 6 or line.lower() in seen:
            continue
        seen.add(line.lower())
        out.append(line)
    return out
```